



Centro Universitário de Brasília (CEUB)

Faculdade de Tecnologia e Ciências Sociais Aplicadas (FATECS)

Thales Rassi Porto de Matos - 22400186

Gabriel Marques da Rocha - 22451254

Gabrielle Gutierrez - 22350026

Pedro Klein - 22105154

Matheus de Moraes - 22352763

Henrique Lessa - 22402204

**Documentação ETL – POPULAÇÃO DE PLANO DE SAÚDE**

Brasília

2025

Thales Rassi Porto de Matos

Gabriel Marques da Rocha

Gabrielle Gutierres

Pedro Klein

Matheus de Moraes

Henrique Lessa

## **Documentação ETL – POPULAÇÃO DE PLANO DE SAÚDE**

Atividade final apresentada à Faculdade de  
Tecnologia e Ciências Sociais Aplicadas  
(FATECS)

, do Centro Universitário de Brasília  
(CEUB) como parte integrante do currículo  
da disciplina Interação Humano  
Computador, da graduação em Ciência da  
computação

Professora responsável: Kadidja Valeria  
Reginaldo de Oliveira

Brasília

2025

## SUMÁRIO

<b>IDENTIFICAÇÃO</b>	04
<b>OBJETIVO DO ETL</b>	04
<b>FONTES DE DADOS DE ENTRADA</b>	04
<b>TABELAS DE DESTINO IMPACTADAS</b>	05
<b>FLUXO DO ETL</b>	05
<b>MAPEAMENTO DE CAMPOS (ORIGEM → DESTINO)</b>	07
<b>DEPENDÊNCIAS E PRÉ-REQUISITOS</b>	07
<b>COMO EXECUTAR</b>	07

## **IDENTIFICAÇÃO**

Script: ETL\_POPULACAO\_DF\_PLANO\_DE\_SAUDE.py

Responsável(is): Equipe Radiologia DF

## **OBJETIVO DO ETL**

Extrair do dataset oficial a população total e a distribuição entre população com e sem plano de saúde por Região Administrativa (RA) do Distrito Federal, padronizar e higienizar os dados, mapear as RAs para seus respectivos identificadores no banco e inserir esses registros na tabela populacao.

Este ETL garante que a base populacional do projeto Radiologia DF esteja normalizada, atualizada e integrada com a dimensão de Regiões Administrativas.

## **FONTES DE DADOS DE ENTRADA**

Arquivo principal (dataset de população por RA):

1. dirty\_data\_pop\_df\_com\_plano\_saude\_por\_ra.csv
  - Caminho esperado: diretório local do projeto
  - Formato: CSV
  - Separador: vírgula (",")
  - Encoding: padrão do pandas (utf-8, salvo ajuste no arquivo)
  - Periodicidade de atualização: conforme disponibilização dos dados populacionais oficiais por RA (anual)

Observação:

- O ano associado à população é definido pela constante ANO\_REFERENCIA = 2021.

## TABELAS DE DESTINO IMPACTADAS

### 1. populacao

- Tabela que armazena a população total, com plano de saúde e sem plano de saúde para cada RA e ano.

## FLUXO RESUMIDO DO ETL

### Passo 1 – Tratamento do dataset bruto

- Verifica se o arquivo definido em DATASET\_PATH existe; caso contrário, lança FileNotFoundError.
- Lê o CSV com separador ";" e engine "python".
- Imprime as colunas encontradas para conferência.
- Valida a existência das colunas obrigatórias:
  - "Local"
  - "Total"
  - "Sim"
  - "Nao"
- Constrói um DataFrame tratado (df\_out) contendo:
  - nome\_ra → obtido a partir de Local, usando a função limpar\_nome\_ra (strip, title case, validação de vazio)
  - populacao\_total → convertida para número, substituindo valores inválidos por 0, convertida para inteiro e limitada a valores  $\geq 0$
  - populacao\_com\_plano\_saude → mesma lógica da coluna anterior
  - populacao\_sem\_plano\_saude → mesma lógica anterior
  - ano → valor fixo definido pela constante ANO\_REFERENCIA = 2021
- Remove linhas onde nome\_ra é nulo.

### Passo 2 – Mapeamento de id\_ra

- Consulta a tabela regioao\_administrativa: SELECT id\_ra, nome FROM regioao\_administrativa;
- Cria um dicionário mapeando nome (lowercase e strip) → id\_ra.
- Atribui ao DataFrame a coluna **id\_ra**, usando esse dicionário.
- Identifica e imprime as RAs não encontradas no banco.

- Remove linhas cujo id\_ra seja nulo, garantindo que apenas RAs válidas serão carregadas.

### Passo 3 – Inserção na tabela populacao

- Monta uma lista de tuplas com os valores: (id\_ra, ano, populacao\_total, populacao\_com\_plano\_saude, populacao\_sem\_plano\_saude)
- Se a lista estiver vazia, imprime aviso e encerra.
- Caso haja registros:
- Insere todos em lote via execute\_values:
  - INSERT INTO populacao (id\_ra, ano, populacao\_total, populacao\_plano\_saude, populacao\_sem\_plano\_saude) VALUES %s;
- Realiza commit.
- Imprime o total de registros inseridos.

### Passo 4 – Encerramento

- Fecha cursor e conexão com o banco.
- Imprime mensagem final indicando a conclusão do ETL.

### **MAPEAMENTO DE CAMPOS (ORIGEM → DESTINO):**

"Local" → nome\_ra → regioao\_administrativa.id\_ra (após mapeamento)

"Total" → populacao\_total

"Sim" → populacao\_com\_plano\_saude

"Nao" → populacao\_sem\_plano\_saude

ANO\_REFERENCIA (2021) → ano

### **DEPENDÊNCIAS E PRÉ-REQUISITOS**

Bibliotecas Python:

- os
- pandas
- psycopg2
- psycopg2.extras
- python-dotenv (load\_dotenv)
- config\_db (função get\_conn para conexão com o banco)

Tabelas:

- regioao\_administrativa (deve conter todos os nomes de RA exatamente como padronizados pelo script)
- populacao (schema compatível com os campos inseridos)

Requisitos de dados

- Arquivo CSV existente no caminho definido em DATASET\_PATH
- Colunas "Local", "Total", "Sim", "Nao" presentes
- Dados numéricos válidos ou coerentes nas colunas populacionais

## **COMO EXECUTAR**

- Garantir que o ambiente virtual (se houver) esteja ativado.
- Garantir que o arquivo .env esteja configurado com os parâmetros de conexão ao banco.
- Verificar que o arquivo dirty\_data\_pop\_df\_com\_plano\_saude\_por\_ra.csv está no caminho esperado.
- Executar: python3 ETL\_POPULACAO\_POR\_RA.py

Pré-condições:

- Banco PostgreSQL acessível.
- Tabela regioao\_administrativa populada e padronizada.
- Tabela populacao criada.